

Optimasi Portofolio Saham Indeks LQ-45 menggunakan Model Predictive Control berdasarkan Hasil Return menggunakan Long Short Term Memory dan Reduce Noise Kalman Filter

Andi Hisyam Helmi F.F
2211110017

Pembimbing :

Andi Prademon Yunus, ST., MSc. Eng., Ph.D.

NIP: 23930008

Dosen Penguji 1 :

Atika Ratna Dewi, S.Si., M.Sc.

NIP: 23870004

Dosen Penguji 2 :

Dian Kartika Sari, S.Si., M.Pd

NIP: 23930003

LATAR BELAKANG

Pertumbuhan ekonomi suatu negara sangat dipengaruhi oleh pasar modal, yang terus menunjukkan peningkatan signifikan secara global dengan kapitalisasi pasar mencapai lebih dari USD 109 triliun pada 2023 [1]. Peningkatan ini mencerminkan peran penting pasar saham dalam mendorong pertumbuhan ekonomi dan inovasi investasi di berbagai negara.

PT Bursa Efek Indonesia (BEI) mencatat rekor baru dengan lebih dari 6 juta investor saham hingga September 2024 [5]

**> 6 Juta
Investor**

**51,5%
Investor Lokal**

Hingga Agustus 2024, investor lokal mendominasi kepemilikan saham dengan 51,5%

[1] H. Zolfagharinia, M. Najafi, S. Rizvi, and A. Haghighi, "Unleashing the Power of Tweets and News in Stock-Price Prediction Using Machine-Learning Techniques," Algorithms, vol. 17, no. 6, Jun. 2024, doi: 10.3390/a17060234.

[5] <https://www.idx.co.id/id/berita/siaran-pers/2224>

LATAR BELAKANG

Seiring dengan peningkatan minat masyarakat terhadap pasar saham, indeks LQ45 muncul sebagai pilihan utama bagi investor. Indeks ini terdiri dari saham-saham yang dipilih berdasarkan kapitalisasi pasar yang besar dan likuiditas tinggi. Kriteria pemilihan ini sangat ketat dan telah diperbarui untuk mencerminkan perkembangan pasar [18].

Tercatat di BEI minimal
3 Bulan

Aktivitas Transaksi

Keadaan Keuangan dan
Prospek Pertumbuhan

Jumlah Hari Perdagangan

Kapitalisasi Pasar

LATAR BELAKANG



RUMUSAN MASALAH

1. Bagaimana mengembangkan model prediksi return saham yang akurat untuk saham-saham indeks LQ-45 dengan horizon 22 hari perdagangan menggunakan LSTM?
2. Bagaimana mengurangi noise pada hasil LSTM menggunakan Kalman Filter untuk meningkatkan kualitas estimasi return saham?
3. Bagaimana mengoptimalkan alokasi portfolio saham indeks LQ-45 secara dinamis menggunakan MPC berdasarkan hasil prediksi return yang sudah difilter?
4. Bagaimana mengintegrasikan ketiga komponen (LSTM, Kalman Filtr, dan MPC) untuk menghasilkan strategi portofolio yang mampu meminimalkan risiko sekaligus memaksimalkan return?

TUJUAN PENELITIAN

1. Mengembangkan model prediksi LSTM yang akurat untuk memprediksi return saham indeks LQ-45 dengan horizon 22 hari perdagangan ke depan.
2. Menerapkan Kalman Filter sebagai teknik filtering untuk mengurangi noise pada hasil prediksi LSTM dan meningkatkan kualitas estimasi return saham.
3. Mengoptimalkan alokasi aset portofolio saham indeks LQ-45 secara dinamis menggunakan MPC dengan mempertimbangkan batasan risiko dan constraint investasi.
4. Mengintegrasikan model prediksi LSTM, Kalman Filter, dan MPC dalam satu framework terpadu untuk menghasilkan strategi manajemen portofolio yang responsif terhadap dinamika pasar.

BATASAN MASALAH

1. Model prediksi return saham yang dikembangkan menggunakan LSTM difokuskan pada prediksi jangka menengah, dengan horizon prediksi 22 hari ke depan.
2. Kalman Filter digunakan sebagai tahap post-processing untuk menyaring noise pada hasil prediksi return dari model LSTM, tanpa mengubah struktur maupun parameter model prediksi.
3. Model prediksi dikembangkan menggunakan data historis dan tidak dirancang untuk pembaruan secara real-time atau implementasi sistem perdagangan langsung.

BATASAN MASALAH

4. Optimasi portofolio dilakukan menggunakan pendekatan Model Predictive Control (MPC) dengan asumsi portofolio bersifat long-only, tanpa mempertimbangkan short selling.
5. Objek penelitian dibatasi pada saham-saham yang tergabung dalam indeks LQ45 selama periode pengamatan.

PENELITIAN TERDAHULU

Optimization of Investment Portfolio Mean-Variance Model Using Genetic Algorithm (Syahla et al., 2024)

Mengoptimalkan portofolio investasi menggunakan model Mean-Variance dan algoritma genetik dengan data saham LQ45 (Feb 2020 - Juli 2021).

Hasil: Lima saham optimal (ADRO, AKRA, BBCA, CPIN, EXCL) dengan return 0.000492 dan risiko 0.000472.

PENELITIAN TERDAHULU

**Investment Portfolio Tracking Using
Model Predictive Control (de Melo,
M.K., Cardoso, R.T.N., Jesus, T.A.,
Raffo, G.V., 2022)**

Menggunakan Model Predictive Control (MPC) untuk melacak portofolio dengan mempertimbangkan biaya transaksi dan horizon prediksi.

Hasil: Sharpe Ratio 3.54 dan RMSE 2570 untuk VPH, lebih baik dibandingkan strategi lain.

PENELITIAN TERDAHULU

Optimalisasi Alokasi Aset di Pasar Modal pada Industri Asuransi Indonesia (Nurdiana Agustina, 2021)

Menggunakan pemrograman linier untuk menentukan bobot alokasi aset di pasar modal dengan data investasi PT Taspen (2020).

Hasil: Alokasi optimal 14,95% saham, 50% obligasi, 18,79% KIK-EBA.

LANDASAN TEORI

MPC (Model Predictive Control)

MPC adalah **metode kontrol** yang menggunakan model matematis sistem **untuk memprediksi perilaku masa depan** dan **mengoptimalkan keputusan kontrol** berdasarkan prediksi tersebut.

MPC mampu **mengatasi berbagai kendala** (misalnya, batasan input, output, dan perubahan keadaan) dalam proses kontrol untuk **menghasilkan keputusan yang optimal** dan **meningkatkan kinerja sistem**.

MPC dapat digunakan dalam **manajemen portofolio investasi** untuk melacak dan **mengoptimalkan alokasi aset** dengan mempertimbangkan faktor risiko dan imbal hasil, serta meningkatkan modal investor.

[39] M. K. de Melo, R. T. Nogueira Cardoso, T. Argolo Jesus, and G. Vianna Raffo, "Investment portfolio tracking using model predictive control," *Optim Control Appl Methods*, vol. 44, no. 1, pp. 259–274, Jan. 2023, doi: 10.1002/oca.2937.

[40] M. Schwenzer, M. Ay, T. Bergs, and D. Abel, "Review on model predictive control: an engineering perspective," Nov. 01, 2021, Springer Science and Business Media Deutschland GmbH. doi: 10.1007/s00170-021-07682-3.

LANDASAN TEORI

Fungsi Objektif

$$\min J(\hat{u}(k)) = \hat{u}^T(k)H\hat{u}(k) + 2f^T\hat{u}(k)$$

LANDASAN TEORI

LSTM (Long Short - Term Memory)

Jaringan saraf yang dikembangkan untuk **memproses data time series** dan mengatasi masalah vanishing gradient, memungkinkan jaringan mempelajari dependensi jangka panjang dalam data.

LSTM terdiri dari tiga komponen utama: Input Gate, Forget Gate, dan Output Gate, yang mengatur aliran informasi dan memutuskan apa yang harus diingat atau dilupakan.

LSTM sangat **efektif** untuk **memprediksi data time series**, karena kemampuannya menangani informasi temporal dan ketergantungan jangka panjang dalam data.

[29] D. I. Puteri, "Implementasi Long Short Term Memory (LSTM) dan Bidirectional Long Short Term Memory (BiLSTM) Dalam Prediksi Harga Saham Syariah," Euler : Jurnal Ilmiah Matematika, Sains dan Teknologi, vol. 11, no. 1, pp. 35–43, May 2023, doi: 10.34312/euler.v11i1.19791.

[30] T. B. Sianturi, I. Cholissodin, and N. Yudistira, "Penerapan Algoritma Long Short-Term Memory (LSTM) berbasis Multi Fungsi Aktivasi Terbobot dalam Prediksi Harga Ethereum," 2023. [Online]. Available: <http://j-ptiik.ub.ac.id>

LANDASAN TEORI

Input Gate

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

Forget Gate

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Output Gate

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

LANDASAN TEORI

Algoritma estimasi yang digunakan untuk memperkirakan **keadaan sistem dinamis** dengan menggabungkan **data pengukuran** dan **model sistem**.

Efektif dalam **mengurangi noise** pada data, sehingga **meningkatkan akurasi estimasi** dan **prediksi**.

Kalman Filter digunakan untuk **memperhalus prediksi return** yang dihasilkan oleh model, membantu **meningkatkan keandalan** dan **stabilitas keputusan investasi**.

KALMAN FILTER

[32] R. I. Alfian, A. Ma'Arif, and S. Sunardi, "Noise reduction in the accelerometer and gyroscope sensor with the Kalman filter algorithm," *Journal of Robotics and Control (JRC)*, vol. 2, no. 3, 2021, doi: 10.18196/jrc.2375.

[33] B. Rudianto, M. Muhafizann Syafwann, and S. Sy, "Algoritma Robust Kalman Filtering untuk Sistem Waktu Kontinu yang Tidak Pasti," *Juni*, vol. 2024, no. 1, pp. 1–11, 2024, [Online]. Available: <http://dx.doi.org/10.xxxx.xxxxxhttps://journal.unindra.ac.id/index.php/sainsmath>

LANDASAN TEORI

Prediksi

$$\bar{x}_k = f(x_{k-1}, u_{k-1}), \quad k \geq 1$$

$$\bar{P}_k = F_{k-1} P_{k-1} F_{k-1}^T + Q$$

Update

$$P_{zz} = H_k \bar{P}_k H_k^T$$


$$P_{xz} = \bar{P}_k H_k^T$$

$$k_k = P_{xz} (P_{zz} + R)^{-1}$$

$$\hat{x}_k = \bar{x}_k + k_k (z_k - h(\bar{x}_k))$$


$$P_k = (I - k_k H_k) \bar{P}_k$$

ALUR PENELITIAN



EDA

Analisis Risk-Return



DATASET

Dataset Saham LQ45

- Kumpulan data **45 perusahaan** pada indeks LQ45 **periode Februari - Juli 2025**
- Periode Data dikumpulkan dari 2 Maret 2015 - 28 Februari 2025
- Variabel Data Saham terdiri dari
 - **Date:** Tanggal perdagangan saham.
 - **Open:** Harga pembukaan saham pada hari tersebut.
 - **Close:** Harga penutupan saham pada hari tersebut.
 - **Low:** Harga terendah saham pada hari tersebut.
 - **High:** Harga tertinggi saham pada hari tersebut.
 - **Adjusted Close:** Harga penutupan yang telah disesuaikan (misalnya untuk dividen atau corporate actions)
 - **Volume:** Jumlah saham yang diperdagangkan pada hari tersebut.

Dataset Saham LQ45

Date	Close	High	Low	Open	Volume
02/03/2015	2335.384	2347.697	2314.862	2323.071	106000000
03/03/2015	2364.115	2392.845	2351.802	2355.906	100000000
04/03/2015	2368.219	2392.846	2360.011	2380.533	61321500
05/03/2015	2380.532	2405.158	2376.428	2380.532	63347500
06/03/2015	2396.95	2409.263	2380.533	2380.533	84722000

Dataset Sentimen

- Data sentimen diperoleh dengan crawling dari platform X
- Crawling menggunakan kata kunci “lq45” dan “saham”
- Data sentimen diubah menjadi proporsi positif, negatif dan netral per harinya
- Jenis Sentimen terdiri dari :
 - Positif: Sentimen yang menunjukkan optimisme atau reaksi positif terhadap saham.
 - Negatif: Sentimen yang menunjukkan kekhawatiran atau reaksi negatif terhadap saham.
 - Netral: Sentimen yang netral atau tidak menunjukkan sentimen yang jelas.

Dataset Sentimen

Date	Positive	Negative	Neutral
2 Maret 2015	0.5	0	0.5
3 Maret 2015	0.25	0.5	0.25
4 Maret 2015	0.181818	0.181818	0.636364
5 Maret 2015	0.809524	0.095238	0.095238
6 Maret 2015	0.818182	0.181818	0

DATA PREPARATION

Data Saham

Feature Engineering

Lagged Returns

- Return lag 1, 2, dan 3 hari sebelumnya
- Memberikan informasi momentum jangka pendek
- Berguna untuk menangkap pattern autoregressive

Technical Indicators

- **Moving Averages**
 - Simple Moving Average (MA): periode 5, 10, 20, 50
 - Exponential Moving Average (EMA): periode 12, 26
- **Momentum Indicators**
 - Relative Strength Index (RSI): periode 14, 21
 - MACD: kombinasi (12,26) dan (5,35)

Scaling

Technical Indicators → MinMaxScaler

- RSI, MACD, Moving Averages
- Scale ke range $[0, 1]$ untuk konsistensi

Volume Features → RobustScaler

- Tahan terhadap outliers
- Tidak sensitif terhadap spike volume ekstrem

Price Features → StandardScaler

- Open, Close, High, Low
- Mengasumsikan distribusi normal

Split Data

Pembagian dataset menggunakan rasio **70% untuk pelatihan, 15% untuk validasi, dan 15% untuk pengujian**

Data Sentimen

Data Sentimen

Data sentimen yang dikumpulkan mulai dari tahun **2015-2025**, dengan data sentimen perharinya mencapai **100+ baris**

Hal ini menjadi problem dalam preprocessing karena total data sentimen yang dikumpulkan mencapai **500 ribu +**

Diperlukan pendekatan yang efisien untuk memastikan klasifikasi sentimen yang **tepat** dan **cepat**

Data Sentimen

Tahap Pertama

Dari lebih **500 ribu data sentimen** yang terkumpul, dilakukan **pengambilan sampel 1500 data** untuk **melatih model** dalam mengidentifikasi sentimen yang relevan dengan saham.



Total data yang relevan sebanyak **60 ribu+** sentimen

Data Sentimen

Tahap Kedua

Dari **60.000+ data relevan**, dilakukan pengambilan **1500 sampel** untuk sentimen manual guna melatih model lebih akurat.



Model yang telah terlatih kemudian diterapkan pada dataset **60.000+ data relevan**, menghasilkan akurasi sentimen sebesar **69%**.

Setelahnya, **proporsi sentimen harian** dihitung untuk memberikan wawasan yang lebih jelas tentang perubahan sentimen pasar setiap hari.

MODELING

Training Fitur


No	Nama Kombinasi	Komponen Fitur
1	<i>Close_LAG_SENT</i>	<i>ret_1d_lag1, ret_1d_lag2, ret_1d_lag3 + Sentimen</i>
2	<i>OHLVC_LAG_SENT</i>	<i>Open, High, Low, Volume, ret_1d_lag1-lag3 + Sentimen</i>
3	<i>OHLVC_LAG_MA_SENT</i>	<i>OHLVC + lag return + MA5, MA10, MA20, MA30, MA50+ Sentimen</i>
4	<i>OHLVC_LAG_EMA_SENT</i>	<i>OHLVC + lag return + EMA5, EMA12, EMA26, EMA30, EMA50+ Sentimen</i>
5	<i>OHLVC_LAG_RSI_SENT</i>	<i>OHLVC + lag return + RSI7, RSI14, RSI21 + Sentimen</i>
6	<i>OHLVC_LAG_MACD_SENT</i>	<i>OHLVC + lag return + MACD_5_20, MACD_10_30, MACD_12_26 + Sentimen</i>
7	<i>OHLVC_LAG_MA_EMA_SENT</i>	<i>OHLVC + lag return + seluruh MA & EMA + Sentimen</i>
8	<i>OHLVC_LAG_RSI_MACD_SENT</i>	<i>OHLVC + lag return + RSI + MACD + Sentimen</i>
9	<i>OHLVC_LAG_MA_EMA_RSI_MACD_SENT</i>	<i>OHLVC + lag return + MA + EMA + RSI + MACD + Sentimen</i>

Note: *ret_nd_lagn* merepresentasikan nilai return pada *n* hari sebelumnya dengan *n=1,2,3*

Scope Tuning LSTM

No	Hyperparameter	Range	Keterangan
1	<i>Dense Units</i>	16, 32, 64	Jumlah Neuron
2	<i>Hidden Units</i>	32,64, 96,128	Jumlah Unit pada Layer LSTM
3	<i>Dropout Rate</i>	0.1 – 0.4	Mengurangi Overfitting
4	<i>Learning Rate</i>	1e-4 – 3e-3	Laju Pembelajaran
5	<i>Batch Size</i>	32, 64, 128	Ukuran Batch
6	<i>Weight Decay</i>	1e-6 sampai 1e-2	Algoritma Optimasi
7	<i>LSTM Layers</i>	1, 2	Jumlah Layer LSTM
8	<i>Huber Delta</i>	0.5, 1, 1.5	Parameter Delta Huber Loss

Hyperparameter Optuna




Training Result


No	Emiten	Fitur	Test RMSE	Test DA	Test IC	Skor DA+IC
1	MEDC	<i>OHLVC_LAG_ MACD_SENT</i>	0.0309	0.564	0.0485	0.782
2	AKRA	<i>OHLVC_LAG_ MA_EMA_RSI_ MACD_SENT</i>	0.0207	0.584	0.0252	0.777
3	ADMR	<i>Close_LAG_S ENT</i>	0.0227	0.585	0.0193	0.762
4	MDKA	<i>OHLVC_LAG_ MA_EMA_RSI_ MACD_SENT</i>	0.0294	0.481	0.0848	0.608
5	BBNI	<i>OHLVC_LAG_ MACD_SENT</i>	0.0173	0.469	0.0919	0.586

Note: Model terbaik setiap emiten dipilih dari berbagai kombinasi fitur dan hasil tuning Optuna (20 trial) berdasarkan akumulasi skor DA dan IC.


MEDC




AKRA




ADMR



MDKA



BBNI



Kalman Result

Emiten	Rata-Rata Prediksi Raw	Rata-Rata Prediksi Kalman	Selisih	Perubahan (%)
MEDC	949.90	949.77	-0.13	-0.014%
AKRA	1,231.58	1,231.58	0	0%
ADMR	766.07	766.17	0.10	0.013%
MDKA	1,435.89	1,436.02	0.13	0.009%
BBNI	3,674.56	3,674.63	0.07	0.002%

Perubahan nilai prediksi setelah Kalman Filter sangat kecil ($\pm 0.00\% - 0.01\%$)

MPC

Hasil Alokasi based on MPC

Emiten	Bobot (%)	Alokasi (Rp)	<i>Expected Return (%)</i>	<i>Realized Return (%)</i>
MEDC	20.94	20,935,333	-6.88	0.5
AKRA	20.87	20,867,908	-7.99	-8.71
ADMR	20.69	20,689,761	-2.33	12.93
MDKA	18.88	18,882,346	2.16	-17.57
BBNI	18.62	18,624,652	-0.77	-4.48

- Bobot saham **terdistribusi relatif merata** ($\pm 18\% - 21\%$)
- **Tidak ada dominasi** pada satu saham tertentu
- Sebagian besar saham memiliki **expected return negatif**
- Hanya MDKA yang memiliki **expected return positif**


Evaluasi Risiko Portofolio

Emiten	Volatilitas	VaR 95% (%)	Sharpe Ratio
MEDC	0.0298	-31.72	-0.637826039
AKRA	0.0635	-59.14	-0.348874755
ADMR	0.0555	-45.9	-0.125222796
MDKA	0.0715	-51.55	0.100195626
BBNI	0.038	-30.62	-0.086043537

Saham **MDKA** dan **AKRA** memiliki **volatilitas** serta nilai **Value-at-Risk (VaR)** yang lebih **tinggi**, sehingga mencerminkan potensi fluktuasi dan **kerugian yang lebih besar**. Sebaliknya, saham seperti **MEDC** dan **BBNI** memiliki tingkat risiko yang relatif lebih rendah dan lebih terkendali.

Sebagian besar saham menunjukkan nilai **Sharpe Ratio negatif**, yang mengindikasikan bahwa **return** yang dihasilkan **belum sebanding dengan risiko yang ditanggung**. Hanya saham MDKA yang memiliki Sharpe Ratio positif, sehingga dinilai lebih efisien dalam menghasilkan return terhadap risiko.

Alokasi



KESIMPULAN

Secara keseluruhan, analisis menunjukkan bahwa terdapat ***trade-off*** yang jelas antara **return dan risiko**, di mana saham dengan potensi **return yang lebih tinggi** cenderung diikuti oleh **tingkat risiko yang lebih besar**.

Selain itu, **sebagian besar saham belum mampu** memberikan **kinerja yang optimal** jika dilihat dari rasio risiko dan return, sehingga menegaskan bahwa **expected return** saja **tidak cukup** sebagai dasar **pengambilan keputusan**.

Oleh karena itu, dalam pembentukan portofolio, diperlukan pendekatan yang lebih komprehensif dengan mempertimbangkan risiko serta efisiensi kinerja agar hasil optimasi lebih optimal dan robust.